Handout Data Lab – GERDA

Wahlergebnisse und regionale Merkmale mit R untersuchen

In diesem Data Lab lernt ihr die **German Election Database (GERDA)** kennen. Ihr arbeitet **zu zweit**, erkundet Wahldaten und verbindet sie mit regionalen Merkmalen. Ziel ist eine erste eigene Auswertung und eine Forschungsfrage, die ihr weiterverfolgen könnt.

1. GERDA kennenlernen · ca. 10 Minuten

Eure Arbeitsgrundlagen:

- GERDA Usage Notes: Auswahl und Interpretation der Wahldaten.
- GERDA R-Paket: Daten laden, Kovariaten ergänzen und Variablen nachschlagen.

Macht euch zuerst mit diesen Arbeitsgrundlagen und anschließend mit dem Election Explorer vertraut. Lest insbesondere **„How to Use the Data“**, **„Denominators, missingness and result versions“** und **„Federal Elections“**.

Verschafft euch einen Überblick über die verfügbaren Variablen, sowie die zeitliche und räumliche Abdeckung.

Klärt gemeinsam:

- Welche Wahlarten und räumlichen Ebenen bietet GERDA?
- Wann benötigt ihr harmonisierte Gebietsstände?
- Auf welche Bezugsgröße beziehen sich die gespeicherten Anteile?
- Welche Einschränkung könnte für eure Auswertung relevant sein?

Ergebnis: Beschreibt in einem Satz, was eine Beobachtung in eurer Auswahl darstellt, und notiert eine relevante Einschränkung.

2. Ein erster Plot: Das Wahlergebnis 2021

Öffnet Rstudio oder Positron, installiert in einem neuen R Script einmal die Pakete `gerda` und `tidyverse`, und inspiziert die verfügbaren Daten. Dieser Code dient als Einstieg:

```
install.packages("gerda")
install.packages("tidyverse")
library(gerda)
library(tidyverse)

# Datenangebot ansehen
gerda_data_list()
```

Wir beschränken uns im weiteren Verlauf auf das file "federal_cty_unharm" im Jahr 2021, die Ergebnisse der Bundestagswahl 2021 auf Kreisebene, und die wichtigsten Parteien.

```
# 1. Kreisdaten der Bundestagswahl 2021 laden
election <- load_gerda_web("federal_cty_unharm",
on_error = "stop") |>
  filter(election_year == 2021)

parteien <- c("cdu_csu", "spd", "gruene", "fdp", "afd",
"linke_pds")
```

Stellt auf Basis der GERDA-Daten dieses Bundestagswahlergebnis in einem einfachen Balkendiagramm dar. Werft dafür einen Blick in die R Graph Gallery.

Achtet darauf: Für ein bundesweites Ergebnis dürft ihr die Kreisanteile nicht einfach mitteln. Gewichtet sie mit der passenden Bezugsgröße und prüft in den Usage Notes, wie die gespeicherten Anteile definiert sind.

```
# 2. Kreisanteile in Stimmenzahlen umrechnen und bundesweit
addieren
ergebnis <- election |>
  summarise(
    across(
      all_of(parteien),
      ~ sum(.x * number_voters) / sum(valid_votes)
    )
  ) |>
  pivot_longer(
    everything(),
    names_to = "partei",
    values_to = "anteil"
  ) |>
  mutate(
    partei = recode(
      partei,
      cdu_csu = "CDU/CSU",
      spd = "SPD",
      gruene = "Grüne",
      fdp = "FDP",
      afd = "AfD",
      linke_pds = "Die Linke"
    )
  )

# Alle weiteren Parteien als Rest zusammenfassen
ergebnis <- ergebnis |>
  add_row(partei = "Sonstige", anteil = 1 -
sum(ergebnis$anteil)) |>
  mutate(
    partei = factor(
      partei,
      levels = c("CDU/CSU", "SPD", "Grüne", "FDP",
                 "AfD", "Die Linke", "Sonstige")
    )
  )
```

Verwendet die üblichen Parteifarben: CDU/CSU schwarz, SPD rot, Grüne grün, FDP gelb, AfD blau und Die Linke violett. Beschriftet die Achsen und gebt die Bezugsgröße der Anteile an.

```
# 3. Parteifarben festlegen
parteifarben <- c(
  "CDU/CSU"  = "#000000",
  "SPD"      = "#E3000F",
  "Grüne"    = "#1AA037",
  "FDP"      = "#FFED00",
  "AfD"      = "#009EE0",
  "Die Linke" = "#BE3075",
  "Sonstige" = "#999999"
)

# 4. Balkendiagramm zeichnen
ggplot(...)


# Diagramm- und Achsenbeschriftung hinzufügen:
+
labs(
  title = "Your Title",
  subtitle = "Your Subtitle",
  x = "your dependent variable",
  y = "your independent variable"
)
```

Ergebnis: Ein beschriftetes Balkendiagramm des Wahlergebnisses 2021.

3. Eine Forschungsfrage und passende Variablen finden · ca. 8 Minuten

Welche regionalen Unterschiede könnten mit Wahlbeteiligung oder Parteiergebnissen zusammenhängen? Wir arbeiten weiterhin mit dem Bundestagswahlergebnis 2021 auf Kreisebene und versuchen, einem solchen regionalen Unterschied plausibel nachzugehen.

```
# Eine Bundestagswahl auf Kreisebene auswählen
election <- load_gerda_web(
  "federal_cty_unharm",
  on_error = "stop"
) |>

filter(election_year == 2021)
```

Der große Vorteil bei GERDA ist, dass anders als etwa bei der CSES, direkt 30 sozio-ökonomische Indikatoren auf Kreisebene im R package mitgeliefert werden. Die Verknüpfung machen wir gleich im nächsten Schritt. Öffnet zuvor das Codebook und verschafft euch einen Überblick:

```
# Öffnet das Covariates Codebook
view(gerda_covariates_codebook())
```

Formuliert auf Grundlage des Codebooks eine erste Frage, beispielsweise:

- *Inwiefern hängt der Anteil von StudentInnen in einem Kreis mit dessen Anteil an Stimmen für Bündnis 90/Die Grünen zusammen?*
- *Wie stark ist die Alternative für Deutschland in Kreisen mit hohem ausländischen Bevölkerungsanteil?*

Prüft die Definitionen, Einheiten und zeitliche Verfügbarkeit der Variablen. Anschließend verknüpft alle Variablen mit dem Ergebnis der Bundestagswahl 2021, wählt die relevant Variablen aus und speichert alles in einem neuen dataframe `data_selection`.

Kontrolliert davor, ob die Verknüpfung erfolgreich war und für wie viele Kreise beide ausgewählten Variablen vorliegen. Ein erfolgreicher Match bedeutet nicht, dass jede Kovariate einen Wert enthält.

```
# Regionale Merkmale ergänzen
election_cov <- add_gerda_covariates(election)

# Verknüpfung und Variablen prüfen
gerda_join_diagnostics(election_cov)

# Auswahl der Variablen
data_selection <- election_cov |>
  select(county_code, election_year, state, state_name,
         afd,                # your dependent variable
         share_foreign)      # your independent variable(s)

glimpse(data_selection)
```

Notiert vor der Auswertung:

- Welche Beziehung erwartet ihr – und warum?
- Was messen eure beiden Variablen genau?
- Passt die räumliche Ebene zu eurer Frage?

Ergebnis: Eine Forschungsfrage, zwei passende Variablen und eine begründete Erwartung.

4. Einen Zusammenhang sichtbar machen · ca. 10 Minuten

Erstellt eine beliebige Darstellung eures Zusammenhangs, beispielsweise in einem einfachen Scatterplot.

- **x-Achse:** eure gewählte Kovariate;
- **y-Achse:** Wahlbeteiligung oder Ergebnis einer gewählten Partei;
- **jeder Punkt:** ein Kreis.

Beschriftet beide Achsen mit Variablennamen und Einheiten. Prüft bei Anteilen die Skala und den Nenner. Fehlende Werte sind keine Nullen.

Beschreibt das Muster: Ist ein Zusammenhang erkennbar? Gibt es Ausreißer? Entspricht das Ergebnis eurer Erwartung?

Überprüft anschließend eure erste Interpretation: Betrachtet beispielsweise ein Bundesland separat oder überlegt, welche zusätzliche Variable den Zusammenhang erklären könnte.

Ergebnis: Eine Grafik und zwei Sätze – einer zur Beobachtung, einer zu einer möglichen Erklärung.

5. Zum Abschluss · 10 Minuten Austausch

Stellt eure Grafik und Forschungsfrage kurz vor:

1. Was habt ihr beobachtet?
2. Was könnt ihr daraus noch nicht schließen?
3. Welchen nächsten Vergleich würdet ihr durchführen?

Ein Zusammenhang zwischen Kreisen erklärt nicht automatisch individuelles Wahlverhalten. Ebenso belegt die Grafik keinen kausalen Effekt. Formuliert eure Schlussfolgerung so, dass sie zu den untersuchten Daten passt.